

PRUEBA TÉCNICA

AI Energy Management Platform

Backend + Frontend + Data + Inteligencia Artificial

Construir un MVP funcional para gestionar medidores eléctricos y utilizar IA para detectar, explicar, priorizar y recomendar acciones sobre anomalías.

Alcance	
Medidores	12
Periodo	14 días
Lecturas	4.032
Variables	Consumo, voltaje, corriente, factor de potencia
Demo	5–10 minutos

1. Objetivo de la prueba

La prueba evalúa la capacidad de construir una solución end-to-end que combine Backend, Frontend, Data/Analytics e Inteligencia Artificial. No se busca únicamente un CRUD de medidores, sino una experiencia que convierta datos en una decisión operativa.

2. Capacidades evaluadas

Backend: API, persistencia y procesamiento. Frontend: UX, dashboard, navegación, filtros y gráficas. Data/Analytics: series temporales, baseline, outliers y calidad de datos. IA: detección, explicación, priorización, confianza y recomendación. Engineering: mantenibilidad, testing y documentación.

La plataforma debe responder:

- ¿Qué está pasando con los medidores?
- ¿Qué lecturas se salen de su comportamiento esperado?
- ¿La anomalía es real, explicable o de calidad de datos?
- ¿Cuál debería investigarse primero?
- ¿Por qué la IA llegó a esa conclusión?
- ¿Qué acción recomienda?

3. Flujo principal

Dashboard → Medidores → Detalle → Anomalías IA → Investigación → Acción

5. Dashboard

KPI	
Medidores	12
Consumo	Consumo total del periodo
Anomalías IA	4 detectadas
Alta prioridad	2
Confianza IA	Métrica agregada
Último análisis	Fecha/hora y estado

6. Gestión de medidores

Medidor	Consumo Variación	Estado	
M-101	820 kWh +2,5%	OK	—
M-104	1.860 kWh +47,6%	Alert	Medium
M-109	2.180 kWh +103,7%	Critical	High
M-112	690 kWh -1,4%	Alert	High

- Filtros: todos, normales, alertas y críticas.
- Búsqueda por meter_id.
- Ordenamiento por consumo, variación o severidad.

7. Detalle de medidor

Debe mostrar consumo actual, baseline, variación, estado e histórico. Idealmente también voltaje, corriente y factor de potencia.

Ejemplo: M-109 · 2.180 kWh · baseline aproximado 1.070 kWh · +103,7%.

8. Motor de anomalías

La técnica es libre: reglas, estadística, Z-score, Isolation Forest, series de tiempo, ML, LLM o combinación. Se evalúa el resultado, no una tecnología específica.

- Spikes/cambios bruscos.
- Cambios persistentes respecto al baseline.
- Outliers.
- Patrones horarios anormales.
- Problemas de calidad de datos.
- Relaciones anómalas entre consumo, voltaje, corriente y factor de potencia.
- Falsos positivos cuando un evento operativo explica el cambio.

9. Casos del dataset

Medidor	Caso	Resultado esperado
M-104	Aumento coincidente con nueva línea productiva.	Anomalía explicable / Medium
M-106	Cambio explicado por parada programada.	False positive / Low
M-109	Aumento >100% sin evento conocido y con cambios eléctricos.	Anomalía real / High
M-112	Consumo estable pero lecturas eléctricas inconsistentes.	Data quality / High

10. Uso de Inteligencia Artificial

La IA no debe limitarse a true/false. Debe generar explicación y recomendación sustentadas por los datos.

```
{
  "meter_id": "M-109",
  "anomaly": true,
  "type": "REAL_ANOMALY",
  "severity": "HIGH",
  "confidence": 0.96,
  "reason": "Consumo 103,7% por encima del baseline sin evento conocido.",
  "recommended_action": "Investigar medidor e instalación."
}
```

11. Pantalla de Anomalías IA

Medidor Tipo Severidad Confianza			
M-109	Real anomaly High	Alta	Investigar
M-112	Data quality High	Alta	Validar
M-104	Explainable anomaly Medium	Alta	Validar operación
M-106	False positive Low	Media/Alta	No escalar

12. Investigación

- Qué encontró la IA.
- Variables que cambiaron.
- Comparación contra baseline.
- Eventos relacionados.
- Severidad y confianza.
- Acción recomendada.
- Evidencia que soporta la explicación.

13. Ejecutar análisis IA

Lecturas → Baseline → Detección → Correlación → Eventos → Explicación → Recomendación

Debe existir un botón Run AI Analysis y mostrar el estado del proceso. Ejemplo final: 4 anomalías detectadas · 2 requieren atención prioritaria.

14. Arquitectura sugerida

Usar como lenguaje go

La arquitectura es libre

15. API mínima sugerida

- GET /meters
- GET /meters/:meterId
- GET /meters/:meterId/readings
- GET /anomalies
- GET /anomalies/:id
- POST /ai/analyze
- GET /ai/analysis/:id
- GET /dashboard/summary

16. Modelo de datos sugerido

Entidad	Campos principales
Meter	id, meter_id, name, location, status, created_at
Reading	id, meter_id, timestamp, consumption_kwh, voltage_v, current_a, power_factor, status
Event Anomaly	id, meter_id, timestamp, type, description id, meter_id, detected_at, type, severity, confidence, reason, recommended_action, status

17. Evaluación global

Competencia	
Frontend / UX	20
Backend / API	20
Data / Analytics	20
Detección de anomalías	15
IA y explicabilidad	15

Testing / documentación / calidad	10
-----------------------------------	----

18. Evaluación específica de IA

Criterio	
Detecta M-109	30
Prioriza M-109	25
Evita tratar M-106 como anomalía real	15
Detecta M-112 como problema de calidad	10
Explica con evidencia	10
Recomienda acción coherente	10

19. Datos entregados

Archivo	Uso	
readings.csv	4.032 lecturas de 12 medidores durante 14 días.	Sí
events.csv expected_results.csv	Eventos operativos conocidos. Ground truth para evaluación.	Sí NO; reservado al evaluador

Importante: expected_results.csv no debe estar disponible para el modelo ni para el usuario final. Se utiliza únicamente para evaluar el desempeño.

20. Entregables

- Repositorio Git.
- Frontend funcional.
- Backend funcional.
- Demo de 5–10 minutos.

21. UX y demo

La aplicación debe sentirse como un producto SaaS de Energy Management y no como una colección de pantallas de prueba.

Login → Dashboard → M-109 → Run AI Analysis → Anomalía → Explicación → Acción

El evaluador debe poder entender en pocos minutos qué aporta la IA.

24. Criterio principal de éxito

La solución debe demostrar el ciclo completo: DATOS → ANÁLISIS → ANOMALÍA → EXPLICACIÓN → PRIORIZACIÓN → ACCIÓN. El valor principal está en que una persona pueda identificar rápidamente qué requiere atención y entender por qué.

Archivos: `readings.csv` · `events.csv` · `expected_results.csv`